

Segmentación de Imágenes Médicas con Redes Convolucionales

*Inteligencia Artificial – Ingeniería del Software
Curso 2025/2026*

Propuesta de Manuel Soriano Trigueros

1. Introducción y Objetivos

La segmentación de imágenes médicas es uno de los retos más fascinantes y críticos en la intersección de la computación y la salud. Este proceso consiste en la **partición digital de una imagen biomédica** (como una resonancia magnética o una tomografía computarizada) en múltiples segmentos o conjuntos de píxeles que comparten características visuales similares. El objetivo técnico es transformar una matriz de datos crudos en una representación semántica, permitiendo que el software identifique y delimite con precisión estructuras anatómicas, órganos o patologías específicas como tumores.

Desde el punto de vista algorítmico, la disciplina ha evolucionado de técnicas clásicas basadas en la detección de bordes hacia arquitecturas complejas de **Deep Learning**, como la famosa **U-Net**. Estas redes neuronales convolucionales realizan una clasificación a nivel de píxel, generando máscaras binarias de alta precisión que facilitan el análisis cuantitativo. El desafío principal reside en el manejo eficiente de datos volumétricos (3D), la reducción del ruido y la garantía de que los modelos sean lo suficientemente robustos para asistir en diagnósticos clínicos reales, donde la precisión es un requisito innegociable.

Una **Red Neuronal Convolutional (CNN)** [1,2] es un tipo de

arquitectura de aprendizaje profundo diseñada específicamente para procesar datos con estructura de rejilla, como las imágenes. A diferencia de las redes tradicionales, las CNN utilizan **capas de convolución** que actúan como filtros automáticos, detectando patrones espaciales (bordes, texturas y formas) mediante el desplazamiento de núcleos (*kernels*) sobre la matriz de píxeles. Esto permite que la red aprenda jerarquías de características de forma eficiente, reduciendo drásticamente el número de parámetros necesarios al compartir pesos en toda la imagen.

Dentro del ámbito de la segmentación, la **U-Net** [3,4] destaca como una arquitectura revolucionaria diseñada originalmente para el análisis de imágenes biomédicas. Su estructura es simétrica y se divide en dos partes principales que le dan su característica forma de "U": un camino de contracción (**encoder**) y un camino de expansión (**decoder**). Mientras que el encoder se encarga de capturar el contexto y reducir la resolución espacial para entender "qué" hay en la imagen, el decoder proyecta esas características a la resolución original para determinar exactamente "dónde" se encuentran.

El elemento diferenciador de la U-Net son las llamadas **conexiones de salto** (*skip connections*). Estas conexiones vinculan directamente las capas del encoder con sus correspondientes capas en el decoder, transfiriendo información de alta resolución que suele perderse durante la fase de compresión. Gracias a esto, la red puede combinar la información semántica profunda con los detalles espaciales precisos, permitiendo generar máscaras de segmentación con bordes mucho más definidos y exactos que otras arquitecturas.

Debido a su diseño eficiente, la U-Net es capaz de entrenarse con relativa rapidez y funcionar excepcionalmente bien incluso con **conjuntos de datos pequeños**, un escenario muy común en medicina donde obtener imágenes etiquetadas es costoso. En la práctica, esto se traduce en una herramienta potente para delimitar píxel a píxel estructuras complejas, desde vasos sanguíneos hasta masas tumorales,

convirtiéndose en el estándar para tareas donde la precisión de la localización es tan vital como la detección misma.




Ilustración 1: arquitectura U-Net introducida en [3]

El **objetivo** de esta propuesta es crear una red neuronal convolucional con arquitectura U-Net y entrenarla para segmentar imágenes biomédicas. Para ello, el/la alumno/a deberá demostrar haber alcanzado los siguientes objetivos específicos:

1. Entender el funcionamiento de una **red convolucional** [1,2], y en especial sus diferencias con otras redes neuronales.
2. Entender en qué consiste la **arquitectura U-Net** [3,4] y el porqué de cada una de sus características.
3. Adquirir un conocimiento básico de las librerías **TensorFlow** [5] y **Keras 3** [6] que permita alcanzar los objetivos 4, 5, 6 y 7.
4. Comprender y usar técnicas de **procesado de datos** e imágenes: *data augmentation*, *padding*, parcheado, etc.

5. Usar correctamente la **métrica** *DICE score* para la evaluación de la segmentación de imágenes.
6. Diseñar y **entrenar** un **modelo** U-Net de segmentación de imágenes que supere el rendimiento mínimo obtenido.
7. Entender el **código** que haya dado lugar al modelo, y cada una de las decisiones tomadas en la programación del mismo.
8. **Generar imágenes** segmentadas con el tamaño y formato requerido.
9. Apoyar el trabajo realizado y los resultados obtenidos en un **informe**, bajo la forma de artículo científico.
10. Explicar y justificar la consecución de los objetivos en una **presentación oral** y responder a las preguntas del profesor.




Ilustración 2: imagen de una aurora boreal junto con una segmentación en 16 colores y otra en 2 colores (fuente: wikimedia commons).

2. Descripción del trabajo

A continuación se describe cómo se debe desarrollar el trabajo, su entrega y exposición.

2.1 Metodología

Para la obtención de los objetivos, el/la alumno/a podrá hacer uso del material visto en clase y la lista de referencias incluidas en este documento (nótese que algunos están en inglés). También podrá usar cualesquiera otros recursos que considere útiles, incluyendo bots conversacionales. En cualquier caso, se evaluará que los/as alumnos/as hayan alcanzado los objetivos específicos, y no la memoria o el código

en sí mismos. También deberá investigar sobre las buenas prácticas en procesamiento de datos – dentro del contexto de segmentación de imágenes médicas – y las métricas más comunes en este campo. En particular:

- Las bases de datos médicas suelen ser muy pequeñas. Por tanto, se deberá seleccionar y ejecutar los mejores métodos para **aumentar los datos** disponibles (*data augmentation*) sin que esto afecte negativamente al entrenamiento del modelo.
- Una de las ventajas de la arquitectura U-Net es que puede alimentarse con imágenes de entradas de distintos tamaños. Esto permite trocear imágenes grandes y difíciles de procesar en otras más pequeñas y manejables. Esta técnica se denomina “**parcheado**” y permite mejorar el entrenamiento a la vez que reduce su costo computacional.
- Hay distintas métricas para evaluar la similitud entre dos segmentaciones distintas de la misma imagen. En este trabajo se usará la **DICE score**, que deberá ser entendida e implementada por el/la alumno/a.

Cuando se esté trabajando con el modelo, se deberá tener en cuenta lo siguiente:

- Por lo general, los conjunto de datos de imágenes médicas suelen tener un tamaño reducido. Si se han procesado los datos correctamente y el modelo está bien diseñado, deberá poder entrenarse en un **ordenador normal**, sin necesidad de usar GPU. No obstante, sí se desea, se podrá usar alojamiento de Jupyter en servidores como Google Colaboratory entre otros.
- En particular, el tamaño reducido del conjunto hace recomendable también que se use **validación cruzada** con al menos 5 pliegues para el entrenamiento del modelo.
- Se recomienda realizar el **preprocesado** del dato a medida que se vaya usando para el entrenamiento, en vez de hacerlo todo de

golpe al principio. Para ello, se puede crear una clase denominada *DataGenerator*.

- Aunque los modelos U-Net permitan imágenes de entrada con distintos tamaños, no todos los tamaños serán válidos. Lo mismo aplicará a las imágenes de salidas. Como el tamaño deseado de nuestras imágenes no tiene por qué coincidir con los que permite la red, habrá que recurrir al *padding* para **añadir o recortar píxeles** de las imágenes según sea necesario.

2.2 Modelos

El modelo creado deberá consistir en una red convolucional con arquitectura U-Net. Deberá devolver, tras un posible postprocesado, imágenes segmentadas con el mismo tamaño que la imagen original.

Las bases de datos usadas variarán según la convocatoria:

- En las convocatorias de **junio** el trabajo debe ser realizado por parejas y en **julio** podrá ser entregado tanto por parejas como individualmente. En ambas convocatorias se deberá usar la base de datos **DRIVE 2004** [7]. Drive es un conjunto de datos público de referencia utilizado en el procesamiento de imágenes médicas para la segmentación automática de vasos sanguíneos en la retina. Compuesta por 40 imágenes (20 de entrenamiento, y 20 de test) de fondo de ojo (fundus) capturadas de pacientes con retinopatía diabética en los Países Bajos, la base de datos se divide equitativamente en conjuntos de entrenamiento y prueba. Cada imagen incluye máscaras de campo de visión (FoV) y segmentaciones manuales de los vasos sanguíneos realizadas por expertos. La segmentación manual es lo que se debe usar como *ground truth* para el entrenamiento y evaluación del modelo. Nótese que en el test se incluyen segmentación manual de dos profesionales distintos. Se espera que el modelo entrenado supere como mínimo un DICE score de **0.75 de media** sobre el conjunto de la imagen y teniendo en cuenta la segmentación de ambos expertos. Es decir, un score de 0.78 de media respecto a la segmentación del primer experto, y uno de 0.74 respecto a la del

segundo experto, tendría una media total de 0.76 y sería dado por bueno.

- En la convocatoria de **octubre** el trabajo se podrá entregar tanto por parejas como individualmente, y se deberá usar una base de datos escogida por el/la alumno/a. Esta deberá consistir en imágenes médicas en 2 dimensiones disponibles públicamente y distintas a la base de datos DRIVE usada en la convocatoria de junio/julio. En el informe correspondiente a esta convocatoria, se deberá justificar por qué se escogió dicho conjunto de datos y una breve descripción del mismo. Se tendrá en cuenta que el modelo tenga un rendimiento aceptable.




Ilustración 3: Ejemplo de imágenes de la base de datos DRIVE con del fondo de ojo a la izquierda y la segmentación de sus vasos sanguíneos la derecha.

2.3 Documentación a entregar

El/la alumno/a deberá entregar:

- El código usado durante todas las fases del desarrollo, incluyendo el preprocesado de las imágenes de entrada, la construcción del modelo, el entrenamiento, la evaluación y el postprocesado de las imágenes de salida.
- La segmentación generada por el modelo a partir de los datos de validación (*test*) en formato *.png*. Es decir, las imágenes que se

han contrapuesto al *ground truth* del conjunto de validación para obtener el *DICE score* del modelo.

- El modelo obtenido en cada pliegue del entrenamiento por validación cruzada, guardado en un documento con extensión *.keras*.
- Un informe bajo la estructura de un **artículo de investigación**, con una longitud de al menos **6 páginas** y obligatoriamente en formato **PDF**. En el portal de la asignatura dispones de plantillas con la estructura base. Se incentivará positivamente el uso de **LaTeX** para la composición del texto. El documento debe estar articulado en los siguientes apartados:
 - Introducción: contextualización del trabajo.
 - Dataset y Objetivo: detalle de los datos y el problema de predicción.
 - Métricas: explicación de las medidas relacionales empleadas.
 - Metodología: descripción del procesado y del modelo, justificación de las decisiones de diseño y análisis de los obstáculos superados.
 - Resultados y Conclusiones: exposición de hallazgos y cierre del estudio.
 - Referencias: bibliografía utilizada.

Bajo ninguna circunstancia se debe incluir código fuente dentro del cuerpo de la memoria.

La entrega consistirá en un fichero .zip con los archivos mencionados. La segmentación de las imágenes y los modelos guardados deberán estar a su vez organizados en carpetas.

2.4 Presentación y defensa

Como parte de la evaluación del trabajo se realizará una presentación oral de 15 minutos, participada por todos/as los/as miembros del equipo de trabajo. Esta charla deberá complementar la memoria entregada (por lo que no debe seguir la misma estructura) y en ella el equipo

deberá demostrar que han logrado los objetivos específicos incluidos en la sección 1 de este documento. Seguidamente, el profesor realizará preguntas a cada uno de los/as participantes durante un máximo de 20 minutos. Todos/as los/as integrantes del grupo deben saber responder a las preguntas independientemente de como se haya repartido el trabajo entre los/as miembros del equipo.

3. Evaluación del trabajo

Para que el trabajo pueda ser evaluado, es imprescindible que el modelo pueda ser cargado usando el `load_model` de Keras 3. La nota final del trabajo tendrá un máximo de 3 puntos, distribuidos como sigue:

- El **código fuente**, las **imágenes segmentadas** generadas y el **modelo** guardado se evaluará sobre un total de **0,5 puntos**. Aquí los/as alumnos/as deberán demostrar que han sido capaces de crear un modelo de red neuronal convolucional con arquitectura U-Net que funciona, realizando el pre- y post-procesamiento necesario a las imágenes con las técnicas mencionadas en el apartado 2.
- La **memoria** del trabajo se evaluará sobre un total de **0,5 puntos**. En ella se deberá demostrar que se entienden los conceptos teóricos usados, y explicar las decisiones tomadas a la hora de escribir el código.
- La **exposición oral** y la correcta respuesta a las **preguntas** serán puntuadas sobre un total de **2 puntos**. En dicha exposición, los/as alumnos/as deberán demostrar que han logrado los objetivos específicos mencionados en el apartado 1, apoyándose y complementando lo que ha sido ya dicho en el código fuente y en la memoria del trabajo. Nótese que las preguntas no solo serán sobre la exposición oral, sino también sobre el código fuente y la memoria. Se recomienda llevar la memoria y el código fuente impresos o en una tablet.

Referencias

[1] Maria Vakalopoulou, Stergios Christodoulidis, Ninon Burgos, Olivier Colliot, Vincent Lepetit. Deep learning: basics and convolutional neural networks (CNN). Olivier Colliot. Machine Learning for Brain Disorders, URL (Capítulo libro): <https://hal.science/hal-03957224v2>

[2] ¡Redes Neuronales CONVOLUCIONALES! ¿Cómo funcionan? URL (VÍDEO): <https://www.youtube.com/watch?v=V8j1oENVz00>

[3] Olaf Ronneberger, Philipp Fischer, Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. URL (borrador de artículo): <https://arxiv.org/abs/1505.04597>

[4] Saidislombek Abdusamatov. Biomedical Image Segmentation with U-Net. URL (Kaggle notebook): <https://www.kaggle.com/code/saidislombek/biomedical-image-segmentation-with-u-net>

[5] Introducción a Tensor Flow. URL (Web): <https://www.tensorflow.org/learn?hl=es-419>

[6] Guía Keras. URL (Web): <https://www.tensorflow.org/guide/keras?hl=es-419>

[7] DRIVE 2004 - Digital Retinal Images for Vessel Extraction URL: <https://www.kaggle.com/datasets/zionfuo/drive2004>