

Procesamiento del lenguaje natural

El Procesamiento del Lenguaje Natural, PLN, (*Natural Language Processing*, NLP, en inglés) es la rama de la Inteligencia Artificial que se ocupa de la formulación e investigación de procedimientos computacionales para el tratamiento del lenguaje humano, es decir, del lenguaje natural. El objetivo último es la comprensión del lenguaje humano por parte de los sistemas computacionales.

Algunas aplicaciones del procesamiento del lenguaje natural son: agentes conversacionales (chatGPT, Gemini); traducción automática (Google Translator, DeepL); reconocimiento del habla (Siri, Google Assistant, Alexa); recuperación y extracción de información (buscadores web); clasificación de documentos (filtros anti-spam); comprobación y autocorrección ortográfica y gramatical.

El desarrollo de sistemas de procesamiento del lenguaje natural requiere de un conocimiento acerca del lenguaje natural considerado que permita al sistema analizar adecuadamente la información recibida. Este conocimiento se estructura en una serie de niveles, que determinan el tipo de análisis a realizar por el sistema.

- Nivel morfológico o léxico: es el conocimiento de cómo son y cómo se forman las palabras del lenguaje. A partir de ese conocimiento, los sistemas de PLN determinan cuáles son las palabras que forman un texto, así como su etiqueta morfosintáctica.
- Nivel sintáctico: es el conocimiento de cómo se combinan las palabras para construir sintagmas y frases. A partir de ese conocimiento, los sistemas de PLN agrupan en sintagmas y frases las palabras identificadas en el nivel anterior.
- Nivel semántico: es el conocimiento de cómo se construye el significado de las palabras y frases. A partir de ese conocimiento, los sistemas de PLN determinan el significado de las frases identificadas en el nivel anterior.
- Nivel pragmático: es el conocimiento de cómo se relaciona el lenguaje con los contextos en los que se usa. A partir de ese conocimiento, los sistemas de PLN establecen la identidad de las personas y objetos, determinan la estructura del discurso y gestionan el diálogo.
- Tratamiento del habla: es el conocimiento de cuáles son los sonidos y fonemas del lenguaje. A partir de ese conocimiento, los sistemas de PLN reconocen y sintetizan el habla.

A grandes rasgos, se pueden considerar dos aproximaciones a la hora de abordar un problema de procesamiento del lenguaje natural:

- En la aproximación simbólica se usan técnicas basadas en la construcción de modelos basados en el conocimiento experto del lenguaje. Es una aproximación descendente, ya que trata de imponer sobre los textos los modelos desarrollados.
- En la aproximación empírica se usan técnicas basadas en el análisis estadístico de grandes volúmenes de texto. Es una aproximación ascendente, ya que los modelos se construyen a partir del propio corpus de texto del que se dispone.

En este tema nosotros usaremos la aproximación empírica para abordar dos tareas concretas de procesamiento del lenguaje natural: la clasificación de documentos y la predicción de secuencias de términos.

Clasificación de documentos

La clasificación de documentos es la tarea de, dado un documento de texto D , asignarle una etiqueta c de entre un conjunto finito C de posibles etiquetas.

La clasificación de documentos tiene numerosas aplicaciones: filtrado de mensajes de correo electrónico no deseados; clasificación automática de mensajes de correo electrónico; control de contenidos infantiles; análisis de sentimientos; etc.

Para realizar clasificación de documentos es necesario en primer lugar construir un modelo de lenguaje que nos permita representar cada documento. Por otra parte, es habitual abordar la clasificación de documentos como una tarea de aprendizaje supervisado, construyendo modelos de clasificación cuyos parámetros se aprenden a partir de un corpus de entrenamiento previamente clasificado.

El primer modelo de lenguaje que vamos a considerar es el conocido como bolsa de palabras (*bag of words*, en inglés). Dado un vocabulario finito de términos V prefijado, cada documento se representa como el vector de la cantidad de veces que ocurre cada término en el documento.

Ejemplo: Bolsa de palabras

Consideremos el poema *Caminante, no hay camino*, de Antonio Machado, tomando las estrofas como los documentos del corpus.

- | | |
|---------|--|
| D_1 : | Caminante, son tus huellas
el camino y nada más; |
| D_2 : | Caminante, no hay camino,
se hace camino al andar. |
| D_3 : | Al andar se hace camino,
y al volver la vista atrás
se ve la senda que nunca
se ha de volver a pisar. |
| D_4 : | Caminante no hay camino
sino estelas en la mar. |

Dado $V = \{\text{caminante, camino, huellas, andar, volver, pisar, estelas, mar}\}$ como vocabulario de términos, el modelo de bolsa de palabras representa cada documento como el vector de ocurrencias de esos términos indicado por la columna correspondiente de la siguiente tabla:

	D_1	D_2	D_3	D_4
caminante	1	1	0	1
camino	1	2	1	1
huellas	1	0	0	0
andar	0	1	1	0
volver	0	0	2	0
pisar	0	0	1	0
estelas	0	0	0	1
mar	0	0	0	1

Basándose en la representación de bolsa de palabras, un modelo de clasificación naive Bayes multinomial asigna a cada documento D la etiqueta $\hat{c}$ dada por

$$\begin{aligned}
 \hat{c} &= \arg \max_{c \in \mathcal{C}} \mathbb{P}(c \mid D) \\
 &= \arg \max_{c \in \mathcal{C}} \mathbb{P}(D \mid c) \mathbb{P}(c) \\
 &= \arg \max_{c \in \mathcal{C}} \left(\mathbb{P}(c) \prod_{t \in V} \mathbb{P}(t \mid c)^{n_{D,t}} \right)
 \end{aligned}$$

donde

- Se ha aplicado la regla de Bayes $\mathbb{P}(c \mid D) = \frac{\mathbb{P}(D \mid c) \mathbb{P}(c)}{\mathbb{P}(D)}$ y se ha tenido en cuenta que el denominador $\mathbb{P}(D)$ no depende de la etiqueta c y, por tanto, no afecta a la hora de calcular cuál de ellas es la más probable.
- Se ha impuesto sobre $\mathbb{P}(D \mid c)$ una distribución multinomial

$$\mathbb{P}(D \mid c) \propto \prod_{t \in V} \mathbb{P}(t \mid c)^{n_{D,t}}$$

donde $\mathbb{P}(t \mid c)$ es la probabilidad de que el término t ocurra en un documento etiquetado con c y $n_{D,t}$ es el número de ocurrencias de t en el documento D .

Para evitar desbordamientos numéricos, en la práctica se calcula

$$\begin{aligned}
 \hat{c} &= \arg \max_{c \in \mathcal{C}} \log \left(\mathbb{P}(c) \prod_{t \in V} \mathbb{P}(t \mid c)^{n_{D,t}} \right) \\
 &= \arg \max_{c \in \mathcal{C}} \left(\log \mathbb{P}(c) + \sum_{t \in V} n_{D,t} \log \mathbb{P}(t \mid c) \right)
 \end{aligned}$$

El aprendizaje de los parámetros del modelo se realiza mediante una estimación de máxima verosimilitud a partir del corpus de entrenamiento, de tal manera que

$$\mathbb{P}(c) = \frac{N_c}{N} \stackrel{\text{def}}{=} \frac{\text{cantidad de documentos etiquetados con } c}{\text{cantidad total de documentos}}$$

$$\mathbb{P}(t | c) = \frac{N_{c,t}}{\sum_{s \in V} N_{c,s}} \stackrel{\text{def}}{=} \frac{\begin{array}{l} \text{número de ocurrencias de } t \\ \text{en documentos etiquetados con } c \end{array}}{\begin{array}{l} \text{número de ocurrencias de todos los términos de } V \\ \text{en documentos etiquetados con } c \end{array}}$$

Para evitar el inconveniente de que alguna de estas estimaciones pueda ser cero, anulando la información aportada por el resto de términos, se puede aplicar la técnica del suavizado. Por ejemplo, con un suavizado de Laplace se tendría

$$\mathbb{P}(t | c) = \frac{N_{c,t} + 1}{\sum_{s \in V} N_{c,s} + |V|}$$

Ejemplo: Clasificación de documentos por un modelo naive Bayes multinomial

Para una tarea de clasificación binaria consideramos como vocabulario de términos $V = \{\text{caminante, camino, huellas, andar, volver, pisar, estelas, mar}\}$ y como conjunto de entrenamiento el poema *Caminante, no hay camino*, en el que suponemos que las estrofas D_1 , D_2 y D_4 son positivas y la estrofa D_3 es negativa. Entonces un modelo naive Bayes multinomial con suavizado de Laplace aprende los siguientes parámetros:

$$\mathbb{P}(\text{documento positivo}) = \frac{3}{4} \quad \mathbb{P}(\text{documento negativo}) = \frac{1}{4}$$

	Clase +												
	D_1	D_2	D_4	Suavizado								$\mathbb{P}(t \mid +)$	
caminante	1	1	1	1	0	0	0	0	0	0	0	0	$\frac{1+1+1+1}{3+4+4+8} = \frac{4}{19}$
camino	1	2	1	0	1	0	0	0	0	0	0	0	$\frac{1+2+1+1}{3+4+4+8} = \frac{5}{19}$
huellas	1	0	0	0	0	1	0	0	0	0	0	0	$\frac{1+0+0+1}{3+4+4+8} = \frac{2}{19}$
andar	0	1	0	0	0	0	1	0	0	0	0	0	$\frac{0+1+0+1}{3+4+4+8} = \frac{2}{19}$
volver	0	0	0	0	0	0	0	1	0	0	0	0	$\frac{0+0+0+1}{3+4+4+8} = \frac{1}{19}$
pisar	0	0	0	0	0	0	0	0	1	0	0	0	$\frac{0+0+0+1}{3+4+4+8} = \frac{1}{19}$
estelas	0	0	1	0	0	0	0	0	0	1	0	0	$\frac{0+0+1+1}{3+4+4+8} = \frac{2}{19}$
mar	0	0	1	0	0	0	0	0	0	0	1	0	$\frac{0+0+1+1}{3+4+4+8} = \frac{2}{19}$
	3	4	4	8									

		Clase –								
	D_3	Suavizado								$\mathbb{P}(t \mid -)$
caminante	0	1	0	0	0	0	0	0	0	$\frac{0+1}{5+8} = \frac{1}{13}$
camino	1	0	1	0	0	0	0	0	0	$\frac{1+1}{5+8} = \frac{2}{13}$
huellas	0	0	0	1	0	0	0	0	0	$\frac{0+1}{5+8} = \frac{1}{13}$
andar	1	0	0	0	1	0	0	0	0	$\frac{1+1}{5+8} = \frac{2}{13}$
volver	2	0	0	0	0	1	0	0	0	$\frac{2+1}{5+8} = \frac{3}{13}$
pisar	1	0	0	0	0	0	1	0	0	$\frac{1+1}{5+8} = \frac{2}{13}$
estelas	0	0	0	0	0	0	0	1	0	$\frac{0+1}{5+8} = \frac{1}{13}$
mar	0	0	0	0	0	0	0	0	1	$\frac{0+1}{5+8} = \frac{1}{13}$
	5	8								

Para clasificar el documento

$D = \text{estelas andar pisar estelas mar pisar}$

cuya representación usando el modelo de bolsa de palabras es el vector

$$(0 \ 0 \ 0 \ 1 \ 0 \ 2 \ 2 \ 1)^T$$

el modelo naive Bayes multinomial calcula

$$\mathbb{P}(+) \prod_{t \in V} \mathbb{P}(t \mid +)^{n_{D,t}} = \frac{3}{4} \left(\frac{4}{19}\right)^0 \left(\frac{5}{19}\right)^0 \left(\frac{2}{19}\right)^0 \left(\frac{2}{19}\right)^1 \left(\frac{1}{19}\right)^0 \left(\frac{1}{19}\right)^2 \left(\frac{2}{19}\right)^2 \left(\frac{2}{19}\right)^1 \approx 2.55 \times 10^{-7}$$

$$\mathbb{P}(-) \prod_{t \in V} \mathbb{P}(t \mid -)^{n_{D,t}} = \frac{1}{4} \left(\frac{1}{13}\right)^0 \left(\frac{2}{13}\right)^0 \left(\frac{1}{13}\right)^0 \left(\frac{2}{13}\right)^1 \left(\frac{3}{13}\right)^0 \left(\frac{2}{13}\right)^2 \left(\frac{1}{13}\right)^2 \left(\frac{1}{13}\right)^1 \approx 4.14 \times 10^{-7}$$

y, por tanto, etiqueta a D como un documento negativo.

El modelo de bolsa de palabras le da la misma importancia a cada uno de los términos del vocabulario, de tal manera que a la hora de clasificar un documento los términos más relevantes son simplemente los que ocurren más a menudo. El modelo de lenguaje tf-idf trata de ajustar esa relevancia, aumentándola para los términos que ocurren mucho en el documento, pero disminuyéndola para los términos que son muy comunes en el corpus de entrenamiento.

Dado un vocabulario finito de términos V prefijado, cada documento se representa como el vector de pesos de cada término en el documento. El peso de un término t en un documento D es

$$tf-idf_{t,D} = tf_{t,D} \times idf_t$$

donde

- $tf_{t,D}$ es la frecuencia del término t (*term frequency*, en inglés) en el documento D , es decir, el número de ocurrencias de t en D .
- df_t es la frecuencia documental del término t (*documental frequency*, en inglés), es decir, el número de documentos del corpus en los que ocurre t .
- idf_t es la frecuencia documental inversa del término t (*inverse documental frequency*, en inglés), calculada como $\log \frac{N}{df_t}$, siendo N la cantidad total de documentos del corpus. De esta forma, los términos raros en el corpus tienen una frecuencia documental inversa alta, mientras que los términos comunes en el corpus tienen una frecuencia documental baja (incluso cero, si el término ocurre en todos los documentos del corpus).

En el caso de un corpus con gran cantidad de documentos (un valor de N grande) o un término raro en el corpus (un valor de df_t pequeño), el valor de N/df_t resultaría excesivamente grande y dominaría completamente sobre $tf_{t,D}$, eliminando de facto la información aportada por esta última. La utilización del logaritmo en la definición de la frecuencia documental inversa la convierte en una función sublineal, amortiguando de esta forma su impacto en el modelo.

Ejemplo: Modelo tf-idf

Dado $V = \{\text{caminante, camino, huellas, andar, volver, pisar, estelas, mar}\}$ como vocabulario de términos, el modelo tf-idf proporciona (tomando 2 como base de los logaritmos) la siguiente representación de las estrofas del poema *Caminante, no hay camino*:

	$tf_{t,D}$				df_t	idf_t	$tf-idf_{t,D}$			
	D_1	D_2	D_3	D_4			D_1	D_2	D_3	D_4
caminante	1	1	0	1	3	$\log_2\left(\frac{4}{3}\right) = 0.415$	0.415	0.415	0	0.415
camino	1	2	1	1	4	$\log_2\left(\frac{4}{4}\right) = 0$	0	0	0	0
huellas	1	0	0	0	1	$\log_2\left(\frac{4}{1}\right) = 2$	2	0	0	0
andar	0	1	1	0	2	$\log_2\left(\frac{4}{2}\right) = 1$	0	1	1	0
volver	0	0	2	0	1	$\log_2\left(\frac{4}{1}\right) = 2$	0	0	4	0
pisar	0	0	1	0	1	$\log_2\left(\frac{4}{1}\right) = 2$	0	0	2	0
estelas	0	0	0	1	1	$\log_2\left(\frac{4}{1}\right) = 2$	0	0	0	2
mar	0	0	0	1	1	$\log_2\left(\frac{4}{1}\right) = 2$	0	0	0	2

Haciendo uso de la representación tf-idf, se puede clasificar un documento mediante un modelo k NN: dado un documento D , se le asigna la etiqueta mayoritaria asignada a los k documentos más similares a D .

La similitud entre dos documentos se mide como el coseno del ángulo que forman sus representaciones tf-idf. Es decir, si el conjunto de términos es $V = \{t_1, \dots, t_n\}$ y los vectores que representan a los documentos D_1 y D_2 son

$$D_1 = (tf-idf_{t_1,D_1}, \dots, tf-idf_{t_n,D_1})^T$$

$$D_2 = (tf-idf_{t_1,D_2}, \dots, tf-idf_{t_n,D_2})^T$$

entonces la similitud entre D_1 y D_2 se calcula como

$$sim(D_1, D_2) = \frac{D_1 \cdot D_2}{\|D_1\|_2 \|D_2\|_2} = \frac{\sum_{i=1}^n tf-idf_{t_i,D_1} tf-idf_{t_i,D_2}}{\sqrt{\sum_{i=1}^n tf-idf_{t_i,D_1}^2} \sqrt{\sum_{i=1}^n tf-idf_{t_i,D_2}^2}}$$

Puesto que $\log_a x = \log_a b \log_b x$, la base utilizada en el cálculo de la representación tf-idf de los documentos es irrelevante, ya que el factor de conversión se cancelaría al aparecer tanto en el numerador como en el denominador.

Ejemplo: Clasificación de documentos por un modelo k NN con $k = 3$

Para una tarea de clasificación binaria consideramos como vocabulario de términos $V = \{\text{caminante, camino, huellas, andar, volver, pisar, estelas, mar}\}$ y como conjunto de entrenamiento el poema *Caminante, no hay camino*, en el que suponemos que las estrofas D_1 , D_2 y D_4 son positivas y la estrofa D_3 es negativa. Entonces un modelo k NN memoriza las representaciones tf-idf de los documentos de entrenamiento:

$$D_1 = (0.415 \ 0 \ 2 \ 0 \ 0 \ 0 \ 0 \ 0)^T \quad D_3 = (0 \ 0 \ 0 \ 1 \ 4 \ 2 \ 0 \ 0)^T$$

$$D_2 = (0.415 \ 0 \ 0 \ 1 \ 0 \ 0 \ 0 \ 0)^T \quad D_4 = (0.415 \ 0 \ 0 \ 0 \ 0 \ 0 \ 2 \ 2)^T$$

Para clasificar el documento

$D = \text{estelas andar pisar estelas mar pisar}$

cuya representación tf-idf es el vector

$$(0 \ 0 \ 0 \ 1 \ 0 \ 2 \ 2 \ 1)^T \odot (0.415 \ 0 \ 2 \ 1 \ 2 \ 2 \ 2 \ 2)^T =$$

$$(0 \ 0 \ 0 \ 1 \ 0 \ 4 \ 4 \ 2)^T$$

el modelo k NN calcula en primer lugar la similitud de D con cada ejemplo de entrenamiento:

$$\begin{aligned}
sim(D, D_1) &= \frac{(0 \times 0.415) + (0 \times 0) + (0 \times 2) + (1 \times 0) + (0 \times 0) + (4 \times 0) + (4 \times 0) + (2 \times 0)}{\sqrt{0^2 + 0^2 + 0^2 + 1^2 + 0^2 + 4^2 + 4^2 + 2^2} \times \sqrt{0.415^2 + 0^2 + 2^2 + 0^2 + 0^2 + 0^2 + 0^2 + 0^2}} \approx 0 \\
sim(D, D_2) &= \frac{(0 \times 0.415) + (0 \times 0) + (0 \times 0) + (1 \times 1) + (0 \times 0) + (4 \times 0) + (4 \times 0) + (2 \times 0)}{\sqrt{0^2 + 0^2 + 0^2 + 1^2 + 0^2 + 4^2 + 4^2 + 2^2} \times \sqrt{0.415^2 + 0^2 + 0^2 + 1^2 + 0^2 + 0^2 + 0^2 + 0^2}} \approx 0.152 \\
sim(D, D_3) &= \frac{(0 \times 0) + (0 \times 0) + (0 \times 0) + (1 \times 1) + (0 \times 4) + (4 \times 2) + (4 \times 0) + (2 \times 0)}{\sqrt{0^2 + 0^2 + 0^2 + 1^2 + 0^2 + 4^2 + 4^2 + 2^2} \times \sqrt{0^2 + 0^2 + 0^2 + 1^2 + 4^2 + 2^2 + 0^2 + 0^2}} \approx 0.323 \\
sim(D, D_4) &= \frac{(0 \times 0.415) + (0 \times 0) + (0 \times 0) + (1 \times 0) + (0 \times 0) + (4 \times 0) + (4 \times 2) + (2 \times 2)}{\sqrt{0^2 + 0^2 + 0^2 + 1^2 + 0^2 + 4^2 + 4^2 + 2^2} \times \sqrt{0.415^2 + 0^2 + 0^2 + 0^2 + 0^2 + 0^2 + 2^2 + 2^2}} \approx 0.690
\end{aligned}$$

Los tres documentos de entrenamiento más similares a D son, entonces, D_2 , D_3 y D_4 , por lo que el modelo etiqueta a D como un documento positivo.

Predicción de secuencias de términos

En muchas tareas dentro del campo del procesamiento del lenguaje natural, el objetivo es obtener una secuencia de términos. Para ello es conveniente construir un modelo de lenguaje que permita calcular las probabilidades de las distintas secuencias. Por ejemplo:

- Para traducir al español, mediante un sistema de traducción automática, la secuencia de palabras en inglés

red blood cells

el modelo de lenguaje debería establecer que

$$\mathbb{P}(\text{glóbulos rojos}) > \mathbb{P}(\text{glóbulos colorados})$$

- En un sistema de corrección ortográfica automática con el que se quisiera corregir la frase

El mercado está a diez *minuts* de mi casa

el modelo de lenguaje indicaría que

$$\begin{aligned}
&\mathbb{P}(\text{El mercado está a diez minutos de mi casa}) > \\
&\mathbb{P}(\text{El mercado está a diez minutas de mi casa})
\end{aligned}$$

- En un sistema de reconocimiento del habla, el modelo de lenguaje podría indicar que

$$\mathbb{P}(\text{vientos fuertes}) > \mathbb{P}(\text{bien, tos fuerte})$$

ayudando a discriminar el mensaje real del usuario.

(Obsérvese la diferencia con, por ejemplo, un modelo naive Bayes multinomial para clasificación de documentos, en el que el objetivo es estimar las probabilidades de distintas etiquetas dada una secuencia de términos, y no la probabilidad de esta última).

Un enfoque simple para calcular las probabilidades de las secuencias de términos es usar una estimación de sus frecuencias relativas. Por ejemplo,

$$\mathbb{P}(\text{El mercado está a diez minutos de mi casa}) = \frac{C(\text{El mercado está a diez minutos de mi casa})}{\sum_{\substack{\text{cualquier posible} \\ \text{secuencia } \mathbf{w}}} C(\mathbf{w})}$$

donde $C(\mathbf{w})$ cuenta cuántas veces aparece la secuencia $\mathbf{w}$ en el corpus.

Desgraciadamente, incluso disponiendo de un corpus extremadamente grande, este enfoque no funcionará en la mayoría de los casos. Por ejemplo, asumiendo un vocabulario pequeño con 10^5 palabras, habrá 10^{100} frases posibles de 20 palabras. Por tanto, la mayoría de esas frases no aparecerán en el corpus de entrenamiento y su probabilidad se estimará como 0.

Los modelos de n -gramas (*n-gram models*, en inglés) abordan el problema mediante una reformulación y una simplificación del mismo.

En primer lugar, aplicando la regla de la cadena transforman la tarea en un problema de predicción de términos: calcular la probabilidad de tener un término en la secuencia dada su historia, donde esta última está formada por todos los términos anteriores en la secuencia. Es decir, supongamos que la secuencia es $\mathbf{w} = w_1 w_2 \cdots w_M$. Entonces,

$$\mathbb{P}(\mathbf{w}) = \mathbb{P}(w_1 w_2 \cdots w_M) = \mathbb{P}(w_1) \mathbb{P}(w_2 \mid w_1) \mathbb{P}(w_3 \mid w_1 w_2) \cdots \mathbb{P}(w_M \mid w_1 \cdots w_{M-1})$$

En segundo lugar, para reducir la combinatoria de manera que sea factible estimar las probabilidades anteriores, aproximan la historia de cada término por el conjunto de únicamente los $n - 1$ términos anteriores. Es decir, dado un término w_m de la secuencia, con historia $w_1 \cdots w_{m-1}$,

$$\mathbb{P}(w_m \mid w_1 \cdots w_{m-1}) \cong \mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1})$$

En definitiva, un modelo de n -gramas estima la probabilidad de una secuencia $\mathbf{w}$ de términos mediante el siguiente producto de probabilidades condicionales:

$$\mathbb{P}(\mathbf{w}) = \mathbb{P}(w_1 w_2 \cdots w_M) \cong \prod_{m=1}^M \mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1})$$

Para evitar desbordamientos numéricos, en la práctica se calcula

$$\log \mathbb{P}(\mathbf{w}) \cong \sum_{m=1}^M \log \mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1})$$

Ejemplo: Modelos unigrama, bigrama y trigramas

Consideremos un vocabulario de términos formado por las palabras del español y usemos los símbolos especiales $\langle s \rangle$ y $\langle /s \rangle$ para marcar el inicio y el final de cada secuencia de términos (el porqué de la introducción de estos símbolos se explicará más adelante). Entonces, para la frase *El mercado está a diez minutos de mi casa*

- Un modelo unigrama ($n = 1$) calcularía

$$\begin{aligned} & \mathbb{P}(\langle s \rangle \text{El mercado está a diez minutos de mi casa} \langle /s \rangle) \cong \\ & \mathbb{P}(\text{El})\mathbb{P}(\text{mercado})\mathbb{P}(\text{está})\mathbb{P}(\text{a})\mathbb{P}(\text{diez})\mathbb{P}(\text{minutos})\mathbb{P}(\text{de})\mathbb{P}(\text{mi})\mathbb{P}(\text{casa})\mathbb{P}(\langle /s \rangle) \end{aligned}$$

- Un modelo bigrama ($n = 2$) calcularía

$$\begin{aligned} & \mathbb{P}(\langle s \rangle \text{El mercado está a diez minutos de mi casa} \langle /s \rangle) \cong \\ & \mathbb{P}(\text{El} \mid \langle s \rangle)\mathbb{P}(\text{mercado} \mid \text{El}) \cdots \mathbb{P}(\text{casa} \mid \text{mi})\mathbb{P}(\langle /s \rangle \mid \text{casa}) \end{aligned}$$

- Un modelo trigramas ($n = 3$) calcularía

$$\begin{aligned} & \mathbb{P}(\langle s \rangle \langle s \rangle \text{El mercado está a diez minutos de mi casa} \langle /s \rangle) \cong \\ & \mathbb{P}(\text{El} \mid \langle s \rangle \langle s \rangle)\mathbb{P}(\text{mercado} \mid \langle s \rangle \text{El})\mathbb{P}(\text{está} \mid \text{El mercado}) \cdots \\ & \mathbb{P}(\text{casa} \mid \text{de mi})\mathbb{P}(\langle /s \rangle \mid \text{mi casa}) \end{aligned}$$

Una manera de estimar las probabilidades $\mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1})$ de los n -gramas es usar el método de máxima verosimilitud, lo que se traduce en calcular la frecuencia relativa, dentro del corpus, de la secuencia $w_{m-(n-1)} \cdots w_{m-1}w_m$ con respecto a todos los n -gramas que comienzan por $w_{m-(n-1)} \cdots w_{m-1}$:

$$\mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1}) = \frac{C(w_{m-(n-1)} \cdots w_{m-1}w_m)}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(w_{m-(n-1)} \cdots w_{m-1}w)}$$

donde V es el vocabulario de términos.

El uso del símbolo especial de fin de secuencia permite deducir fácilmente que la frecuencia del $(n - 1)$ -grama $w_{m-(n-1)} \cdots w_{m-1}$ coincide con la suma de las frecuencias de todos los n -gramas $w_{m-(n-1)} \cdots w_{m-1}w$ que comienzan por él. Por lo tanto, la estimación de las probabilidades de los n -gramas queda como

$$\mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1}) = \frac{C(w_{m-(n-1)} \cdots w_{m-1}w_m)}{C(w_{m-(n-1)} \cdots w_{m-1})}$$

Ejemplo: Estimación de probabilidades en modelos unigrama, bigrama y trigramas

Considerando el vocabulario V de términos formado por las palabras del español,

- En un modelo unigrama

$$\begin{aligned}
 \mathbb{P}(\text{El}) &= \frac{C(\text{El})}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(w)} \\
 &= \frac{\text{veces que aparece «El» en el corpus}}{\text{cantidad de palabras y frases que hay en el corpus}} \\
 \mathbb{P}(\text{mercado}) &= \frac{C(\text{mercado})}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(w)} \\
 &= \frac{\text{veces que aparece «mercado» en el corpus}}{\text{cantidad de palabras y frases que hay en el corpus}} \\
 &\vdots \\
 \mathbb{P}(\langle /s \rangle) &= \frac{C(\langle /s \rangle)}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(w)} \\
 &= \frac{\text{cantidad de frases que hay en el corpus}}{\text{cantidad de palabras y frases que hay en el corpus}}
 \end{aligned}$$

- En un modelo bigrama

$$\begin{aligned}
 \mathbb{P}(\text{El} \mid \langle s \rangle) &= \frac{C(\langle s \rangle \text{El})}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(\langle s \rangle w)} = \frac{C(\langle s \rangle \text{El})}{C(\langle s \rangle)} \\
 &= \frac{\text{cantidad de frases del corpus que comienzan por «El»}}{\text{cantidad de frases que hay en el corpus}} \\
 \mathbb{P}(\text{mercado} \mid \text{El}) &= \frac{C(\text{El mercado})}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(\text{El } w)} = \frac{C(\text{El mercado})}{C(\text{El})} \\
 &= \frac{\text{veces que aparece «El mercado» en el corpus}}{\text{veces que aparece «El» en el corpus}} \\
 &\vdots \\
 \mathbb{P}(\langle /s \rangle \mid \text{casa}) &= \frac{C(\text{casa} \langle /s \rangle)}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(\text{casa } w)} = \frac{C(\text{casa} \langle /s \rangle)}{C(\text{casa})} \\
 &= \frac{\text{cantidad de frases del corpus que terminan por «casa»}}{\text{veces que aparece «casa» en el corpus}}
 \end{aligned}$$

- En un modelo trigramas

$$\begin{aligned}
 \mathbb{P}(\text{El} \mid \langle s \rangle \langle s \rangle) &= \frac{C(\langle s \rangle \langle s \rangle \text{El})}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(\langle s \rangle \langle s \rangle w)} = \frac{C(\langle s \rangle \langle s \rangle \text{El})}{C(\langle s \rangle \langle s \rangle)} \\
 &= \frac{\text{cantidad de frases del corpus que comienzan por «El»}}{\text{cantidad de frases que hay en el corpus}}
 \end{aligned}$$

$$\begin{aligned}
\mathbb{P}(\text{mercado} \mid \langle s \rangle \text{El}) &= \frac{C(\langle s \rangle \text{El mercado})}{\sum_{w \in V \cup \{\langle s \rangle\}} C(\langle s \rangle \text{El } w)} = \frac{C(\langle s \rangle \text{El mercado})}{C(\langle s \rangle \text{El})} \\
&= \frac{\text{cantidad de frases del corpus que comienzan por «El mercado»}}{\text{cantidad de frases del corpus que comienzan por «El»}} \\
\mathbb{P}(\text{está} \mid \text{El mercado}) &= \frac{C(\text{El mercado está})}{\sum_{w \in V \cup \{\langle s \rangle\}} C(\text{El mercado } w)} = \frac{C(\text{El mercado está})}{C(\text{El mercado})} \\
&= \frac{\text{veces que aparece «El mercado está» en el corpus}}{\text{veces que aparece «El mercado» en el corpus}} \\
&\vdots \\
\mathbb{P}(\langle /s \rangle \mid \text{mi casa}) &= \frac{C(\text{mi casa} \langle /s \rangle)}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(\text{mi casa } w)} = \frac{C(\text{mi casa} \langle /s \rangle)}{C(\text{mi casa})} \\
&= \frac{\text{cantidad de frases del corpus que terminan por «mi casa»}}{\text{veces que aparece «mi casa» en el corpus}}
\end{aligned}$$

El símbolo especial $\langle s \rangle$ de inicio de secuencia se introduce por conveniencia, para poder descomponer de forma homogénea la probabilidad de una secuencia como producto de las probabilidades de los n -gramas que la forman. Por ejemplo, si no se usara ese símbolo especial, entonces un modelo bigrama tendría que calcular

$$\begin{aligned}
&\mathbb{P}(\text{El mercado está a diez minutos de mi casa} \langle /s \rangle) \cong \\
&\mathbb{P}(\text{El})\mathbb{P}(\text{mercado} \mid \text{El}) \cdots \mathbb{P}(\text{casa} \mid \text{mi})\mathbb{P}(\langle /s \rangle \mid \text{casa})
\end{aligned}$$

donde el primer término del producto sería un unigrama, en lugar de un bigrama.

Sin embargo, el símbolo especial $\langle /s \rangle$ de fin de secuencia sí es necesario para que el modelo de n -gramas proporcione una distribución de probabilidad sobre *todas* las posibles secuencias de términos. Si no se usara, el modelo proporcionaría en su lugar una distribución de probabilidad distinta para cada conjunto de secuencias de la misma longitud.

Por ejemplo, consideremos $\{a, b\}$ como vocabulario de términos. Sin el símbolo especial de fin de secuencia, un modelo bigrama entrenado a partir del corpus $\langle s \rangle \text{aba}$, $\langle s \rangle \text{ab}$, $\langle s \rangle \text{bb}$ asignaría las siguientes probabilidades a cada una de las posibles secuencias de dos términos:

$$\begin{aligned}
\mathbb{P}(\langle s \rangle \text{aa}) &= \mathbb{P}(a \mid \langle s \rangle)\mathbb{P}(a \mid a) = \frac{C(\langle s \rangle a)}{\sum_{w=a,b} C(\langle s \rangle w)} \frac{C(aa)}{\sum_{w=a,b} C(aw)} = \frac{2}{3} \frac{0}{2} = 0 \\
\mathbb{P}(\langle s \rangle \text{ab}) &= \mathbb{P}(a \mid \langle s \rangle)\mathbb{P}(b \mid a) = \frac{C(\langle s \rangle a)}{\sum_{w=a,b} C(\langle s \rangle w)} \frac{C(ab)}{\sum_{w=a,b} C(aw)} = \frac{2}{3} \frac{2}{2} = \frac{2}{3} \\
\mathbb{P}(\langle s \rangle \text{ba}) &= \mathbb{P}(b \mid \langle s \rangle)\mathbb{P}(a \mid b) = \frac{C(\langle s \rangle b)}{\sum_{w=a,b} C(\langle s \rangle w)} \frac{C(ba)}{\sum_{w=a,b} C(bw)} = \frac{1}{3} \frac{1}{2} = \frac{1}{6} \\
\mathbb{P}(\langle s \rangle \text{bb}) &= \mathbb{P}(b \mid \langle s \rangle)\mathbb{P}(b \mid b) = \frac{C(\langle s \rangle b)}{\sum_{w=a,b} C(\langle s \rangle w)} \frac{C(bb)}{\sum_{w=a,b} C(bw)} = \frac{1}{3} \frac{1}{2} = \frac{1}{6}
\end{aligned}$$

Estas probabilidades suman 1 y, por tanto, establecen una distribución de probabilidad sobre todas las secuencias de dos términos. En consecuencia, no es posible que este

modelo bigrama proporcione una distribución de probabilidad sobre todas las posibles secuencias que usen los términos a y b.

Por el contrario, con el símbolo especial de fin de secuencia un modelo bigrama entrenado a partir del corpus $\langle s \rangle aba \langle /s \rangle$, $\langle s \rangle ab \langle /s \rangle$, $\langle s \rangle bb \langle /s \rangle$ asignaría las siguientes probabilidades de cada una de las posibles secuencias de dos símbolos:

$$\mathbb{P}(\langle s \rangle aa \langle /s \rangle) = \mathbb{P}(a \mid \langle s \rangle) \mathbb{P}(a \mid a) \mathbb{P}(\langle /s \rangle \mid a) = \frac{C(\langle s \rangle a)}{C(\langle s \rangle)} \frac{C(aa)}{C(a)} \frac{C(a \langle /s \rangle)}{C(a)} = \frac{2}{3} \frac{0}{3} \frac{1}{3} = 0$$

$$\mathbb{P}(\langle s \rangle ab \langle /s \rangle) = \mathbb{P}(a \mid \langle s \rangle) \mathbb{P}(b \mid a) \mathbb{P}(\langle /s \rangle \mid b) = \frac{C(\langle s \rangle a)}{C(\langle s \rangle)} \frac{C(ab)}{C(a)} \frac{C(b \langle /s \rangle)}{C(b)} = \frac{2}{3} \frac{2}{3} \frac{2}{4} = \frac{2}{9}$$

$$\mathbb{P}(\langle s \rangle ba \langle /s \rangle) = \mathbb{P}(b \mid \langle s \rangle) \mathbb{P}(a \mid b) \mathbb{P}(\langle /s \rangle \mid a) = \frac{C(\langle s \rangle b)}{C(\langle s \rangle)} \frac{C(ba)}{C(b)} \frac{C(a \langle /s \rangle)}{C(a)} = \frac{1}{3} \frac{1}{4} \frac{1}{3} = \frac{1}{36}$$

$$\mathbb{P}(\langle s \rangle bb \langle /s \rangle) = \mathbb{P}(b \mid \langle s \rangle) \mathbb{P}(b \mid b) \mathbb{P}(\langle /s \rangle \mid b) = \frac{C(\langle s \rangle b)}{C(\langle s \rangle)} \frac{C(bb)}{C(b)} \frac{C(b \langle /s \rangle)}{C(b)} = \frac{1}{3} \frac{1}{4} \frac{2}{4} = \frac{1}{24}$$

Estas probabilidades ya no suman 1.

Otra manera de entender los modelos de n -gramas es considerarlos modelos generativos de secuencias de términos, usando las probabilidades condicionales para producir un término detrás de otro. Por ejemplo, dado el corpus anterior, un modelo bigrama generaría con mayor probabilidad una secuencia comenzando por a que por b, puesto que $\mathbb{P}(a \mid \langle s \rangle) = 2/3 > 1/3 = \mathbb{P}(b \mid \langle s \rangle)$. A partir de ese primer término generado, se irían añadiendo nuevos términos a la secuencia en función de las distribuciones condicionales entrenadas, hasta generar un símbolo $\langle /s \rangle$. Así, en el ejemplo que nos ocupa es más probable terminar la secuencia si el último término generado ha sido b que si ha sido a, ya que $\mathbb{P}(\langle /s \rangle \mid a) = 1/3$, mientras que $\mathbb{P}(\langle /s \rangle \mid b) = 1/2$.

Obsérvese que, desde esta perspectiva generativa, el uso del símbolo especial $\langle /s \rangle$ está modelizando la distribución de probabilidad de la longitud de la secuencia. Es decir, un procedimiento equivalente sería determinar primero de manera aleatoria de cuántos términos va a constar la secuencia y luego generar esa cantidad de términos según las distribuciones condicionales correspondientes. Sin embargo, la estimación de esa distribución de probabilidad de la longitud de la secuencia sería un cálculo más laborioso.

Cuando en una secuencia aparece un término en un contexto desconocido, el modelo de n -gramas le asigna probabilidad cero y, en consecuencia, también le asigna esa probabilidad a la secuencia completa. Por ejemplo, el modelo bigrama construido anterioremente le asigna probabilidad cero a la secuencia aa ($\mathbb{P}(\langle s \rangle aa \langle /s \rangle) = 0$), ya que en el corpus nunca ha aparecido una a seguida de otra a ($\mathbb{P}(a \mid a) = 0$).

Una manera simple de evitar este problema es aplicar una técnica de suavizado, considerando, al calcular las distribuciones de probabilidad condicionales, k secuencias virtuales que terminen en cada uno de los términos del vocabulario V (y también en el símbolo especial de fin de secuencia). Es decir,

$$\mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1}) = \frac{C(w_{m-(n-1)} \cdots w_{m-1} w_m) + k}{\sum_{w \in V \cup \{\langle /s \rangle\}} C(w_{m-(n-1)} \cdots w_{m-1} w) + (|V| + 1)k}$$

donde $|V|$ es la cantidad de términos del vocabulario.

Ejemplo: Modelo bigrama con suavizado

Dado el vocabulario $V = \{a, b\}$, entrenar un modelo bigrama con el corpus $\langle s \rangle aba \langle /s \rangle$, $\langle s \rangle ab \langle /s \rangle$, $\langle s \rangle bb \langle /s \rangle$, aplicando un suavizado de Laplace ($k = 1$), proporciona las siguientes distribuciones condicionales:

$$\begin{aligned} \mathbb{P}(a \mid \langle s \rangle) &= \frac{2+1}{3+3} = \frac{1}{2} & \mathbb{P}(a \mid a) &= \frac{0+1}{3+3} = \frac{1}{6} & \mathbb{P}(a \mid b) &= \frac{1+1}{4+3} = \frac{2}{7} \\ \mathbb{P}(b \mid \langle s \rangle) &= \frac{1+1}{3+3} = \frac{1}{3} & \mathbb{P}(b \mid a) &= \frac{2+1}{3+3} = \frac{1}{2} & \mathbb{P}(b \mid b) &= \frac{1+1}{4+3} = \frac{2}{7} \\ \mathbb{P}(\langle /s \rangle \mid \langle s \rangle) &= \frac{0+1}{3+3} = \frac{1}{6} & \mathbb{P}(\langle /s \rangle \mid a) &= \frac{1+1}{3+3} = \frac{1}{3} & \mathbb{P}(\langle /s \rangle \mid b) &= \frac{2+1}{4+3} = \frac{3}{7} \end{aligned}$$

Por tanto, ahora se tendría

$$\mathbb{P}(\langle s \rangle aa \langle /s \rangle) = \mathbb{P}(a \mid \langle s \rangle) \mathbb{P}(a \mid a) \mathbb{P}(\langle /s \rangle \mid a) = \frac{1}{2} \frac{1}{6} \frac{1}{3} = \frac{1}{36}$$

Otra manera de abordar el problema es recurrir a modelos de nivel inferior si un determinado n -grama no aparece en el corpus de entrenamiento. La manera más simple de hacerlo es mediante retroceso (*backoff*, en inglés): si $\mathbb{P}(w_m \mid w_{m-(n-1)} \cdots w_{m-1})$ es cero porque el n -grama $w_{m-(n-1)} \cdots w_{m-1} w_m$ no aparece en el corpus, utilizamos en su lugar $\mathbb{P}(w_m \mid w_{m-(n-2)} \cdots w_{m-1})$. Si esta probabilidad también es cero, reducimos de nuevo el contexto, y así reiteradamente hasta llegar, en su caso, a los unigramas.

Otra posibilidad es utilizar una interpolación lineal entre varios modelos de n -gramas. Por ejemplo, para interpolar un modelo bigrama con un modelo unigrama se calcularía

$$\mathbb{P}(w_m \mid w_{m-1}) = \lambda_1 \mathbb{P}_1(w_m) + \lambda_2 \mathbb{P}_2(w_m \mid w_{m-1})$$

donde $\mathbb{P}_1$ y $\mathbb{P}_2$ son, respectivamente, las probabilidades proporcionadas por los modelos unigrama y bigrama. Además, para que se tenga que $\mathbb{P}$ sea verdaderamente una distribución de probabilidad, los coeficientes de la interpolación están sujetos a las restricciones $\lambda_1, \lambda_2 > 0$ y $\lambda_1 + \lambda_2 = 1$.

Ejemplo: Interpolación de un modelo bigrama con un modelo unigrama

Se interpola un modelo bigrama con un modelo unigrama tomando $\lambda_1 = \lambda_2 = 1/2$. Para el ejemplo anterior se tendría, entonces

$$\begin{aligned} \mathbb{P}(\langle s \rangle aa \langle /s \rangle) &= \mathbb{P}(a \mid \langle s \rangle) \mathbb{P}(a \mid a) \mathbb{P}(\langle /s \rangle \mid a) \\ &= \left(\frac{1}{2} \mathbb{P}_1(a) + \frac{1}{2} \mathbb{P}_2(a \mid \langle s \rangle) \right) \left(\frac{1}{2} \mathbb{P}_1(a) + \frac{1}{2} \mathbb{P}_2(a \mid a) \right) \left(\frac{1}{2} \mathbb{P}_1(\langle /s \rangle) + \frac{1}{2} \mathbb{P}_2(\langle /s \rangle \mid a) \right) \\ &= \left(\frac{1}{2} \frac{3}{10} + \frac{1}{2} \frac{2}{3} \right) \left(\frac{1}{2} \frac{3}{10} + \frac{1}{2} \frac{0}{3} \right) \left(\frac{1}{2} \frac{3}{10} + \frac{1}{2} \frac{1}{3} \right) \\ &= \frac{551}{24000} \end{aligned}$$

La mejor manera de evaluar el rendimiento de los modelos de n -gramas es mediante una evaluación extrínseca: usarlo en una aplicación y medir cuánto mejora esta. Por ejemplo, en un sistema de reconocimiento del habla podemos comparar el rendimiento de dos modelos de n -gramas ejecutando el sistema dos veces, una con cada modelo, y observar cuál proporciona una transcripción más precisa.

Desafortunadamente, una evaluación extrínseca es en general costosa. En su lugar, sería más factible realizar una evaluación intrínseca, en la que la calidad del modelo de n -gramas se mide de forma independiente de la aplicación. Para realizar una evaluación intrínseca se necesita un corpus de prueba adicional al corpus de entrenamiento.

El rendimiento de un modelo de n -gramas se mide entonces en función de su perplejidad sobre el corpus de prueba, que se calcula como el inverso de la probabilidad asignada por el modelo al corpus, normalizado por el número de términos del vocabulario contenidos en el corpus. Es decir, si las secuencias del corpus de prueba son $\mathbf{w}_1, \dots, \mathbf{w}_M$ y en total estas contienen N términos de $V \cup \{\langle/s\rangle\}$, entonces

$$\text{Perplejidad}(\mathbf{w}_1 \dots \mathbf{w}_M) = \sqrt[N]{\frac{1}{\prod_{i=1}^M \mathbb{P}(\mathbf{w}_i)}}$$

Para evitar desbordamientos numéricos, en la práctica la perplejidad de un corpus de prueba se calcula como

$$\text{Perplejidad}(\mathbf{w}_1 \dots \mathbf{w}_M) = 2^{\log_2 \sqrt[N]{\frac{1}{\prod_{i=1}^M \mathbb{P}(\mathbf{w}_i)}}} = 2^{-\frac{1}{N} \sum_{i=1}^M \log_2 \mathbb{P}(\mathbf{w}_i)}$$

Un modelo será por tanto mejor cuanto menor sea su perplejidad sobre el corpus de prueba, y esta es inversamente proporcional a la probabilidad asignada al corpus por el modelo y a la cantidad de términos contenidos en el corpus.